


工場環境下における教師なし異常音検知 システムの構築

金沢工業大学 中沢研究室 山上楓峨



目次

1. 研究背景

2. 研究課題と目的

3. 進捗状況

4. まとめと今後の展望

1. 研究背景

産業現場での異常音検知の重要性



工場の安全な稼働を維持する上で、機械の設備点検業務は非常に重要

産業現場において機械の音から自動で異常を発見する
異常音検知システムは盛んにおこなわれている

機械の異常を**早期に発見**することは、事故や故障の**拡大防止**につながる

人による点検には、**見逃し**や担当者による**判断の違い**がある



本研究では、機械の音から**自動で異常を発見する**異常音検知に取り組む

2. 研究課題と目的

課題①異常音データの収集が困難

→ 異常音データを使用せずに異常を検知できる教師なし異常検知の実現

課題②環境騒音による精度低下


→ 環境騒音の影響を受けにくい異常音検知システムの構築



正常音のみで学習し、工場騒音がある環境でも異常を
検知できるシステムの構築を目指す

3. 進捗状況

3-1. 現在の異常音検知システムの構成



3-1. 現在の異常音検知システムの構成

① 正常な音声データ

② 4つの方法で
特徴抽出

Mel + CNN

BEATs

EAT

SSLAM

各特徴で③～⑥を個別で実行

③ 擬似ラベル生成
正常音の中でも似た音を
グループ化

④ 分類モデルを学習
新たな正常音のグループ
番号を予測

⑤ 正常分布構築
分類モデルをもとに構築

⑥ 異常スコア計算
評価用音声データと正常
分布との距離

⑦ 4つの異常スコアをアンサンブル

⑧ アンサンブルした異常スコアをもとにAUC/pAUC算出

3-2. 対象データ：学習・評価に使用したValve音

DCASE Challenge Task2「機械状態監視のための初回無監視異常音検出」

対象機械から発せられる音が正常か異常かを識別するタスク異常音検知の手法について技術を競うワークショップ
6つの機械音が対象 → **その中の1つvalve音**で検証する

学習データには正常音のみを使用


評価データには正常音と異常音を使用




正常音



異常音



3-1. 現在の異常音検知システムの構成



3-3. 4つの音響特徴抽出方法と期待される特徴

特徴抽出方法の基盤となる論文

特徴抽出方法	基盤となる論文
メロスペクトログラム+ CNN	The NU Systems for DCASE 2025 Challenge Task 2 Fujimura et al., DCASE 2025 Technical Report
BEATs	BEATs: Audio Pre-Training with Acoustic Tokenizers Chen et al., ICML 2023
EAT	EAT: Self-Supervised Pre-Training with Efficient Audio Transformer Chen et al., arXiv:2401.03497, 2024
SSLAM	SSLAM: Enhancing Self-Supervised Models with Audio Mixtures for Polyphonic Soundscapes Alex et al., ICLR 2025

3-3. 4つの音響特徴抽出方法と期待される特徴

期待される特徴比較表

特徴抽出方法 / どのような特徴を捉えるか	周波数・音量の細かな変化 例：対象機械の音	音声全体の周波数的な変化 例：対象機械の全体の音	一瞬だけ発生する変化 例：一瞬だけ対象機械から異常音が入る音	複数の音が重なる変化 例：対象機械だけでなく背景騒音も入る音
メロスペクトログラム+CNN	◎	○	○	△
BEATs	△	◎	△	△
EAT	△	◎	◎	△
SSLAM	△	○	△	◎



◎：特に捉えると期待される
○：捉えられる可能性がある
△：主な特徴ではない

4つの方法は特徴が異なるため、同じ対象機械から異なる特徴を抽出する可能性

3-1. 現在の異常音検知システムの構成

① 正常な音声データ

② 4つの方法で
特徴抽出

Mel + CNN

BEATs

EAT

SSLAM

各特徴で③～⑥を個別で実行

③ 擬似ラベル生成
正常音の中でも似た音を
グループ化

④ 分類モデルを学習
新たな正常音のグループ
番号を予測

⑤ 正常分布構築
分類モデルをもとに構築

⑥ 異常スコア計算
評価用音声データと正常
分布との距離

③ 正常音の特徴



④

正常音 A


正常音 B

正常音 C


分類モデル

新しい正常音が
どのグループか予測

⑤




3-1. 現在の異常音検知システムの構成



3-4. 異常スコア：異常スコアの計算方法

異常スコアの仕組み

1. 評価用音声データの特徴を抽出
2. 学習用音声データで構築した**正常分布と比較**
3. 正常分布内のそれぞれの**正常音グループ**と**コサイン距離を算出**
4. **コサイン距離が最小のものを選択**
5. それを評価音の**異常スコア**とする



異常スコアの選択例

正常音グループ	正常音グループとの距離	選択
正常音A	0.10	○
正常音B	0.60	-
正常音C	0.75	-


異常スコアが**小さい**

= 学習用正常音の中に**似た音が存在する**
正常音の可能性高

異常スコアが**大きい**

= どの学習用正常音とも**似ていない**
異常音の可能性高

3-1. 現在の異常音検知システムの構成



3-5. アンサンブル：4つの評価結果のアンサンブル

アンサンブルとは

複数の特徴量やモデルの結果を**組み合わせて**、最終的な判定を行う手法


アンサンブルの仕組み

1. 同じテストvalve音データからメロスペクトログラム、BEATs、EAT、SSLAM
のそれぞれで、**異常スコアを算出**
2. その4つの異常スコアに**重みを設定**して統合し、**最大値**を最終の**異常スコア**にする
$$S_{\text{ensemble}} = W_{\text{Mel}} S_{\text{Mel}} + W_{\text{BEATs}} S_{\text{BEATs}} + W_{\text{EAT}} S_{\text{EAT}} + W_{\text{SSLAM}} S_{\text{SSLAM}}$$
 S : 異常スコア W : 重み
3. この処理を全テストデータに対して行って、**AUCとpAUCを算出する**



1つのモデルが**異常を見逃しても**、別のモデルの異常スコアによって
補うことを目的とする

3-1. 現在の異常音検知システムの構成



3-6. 評価方法：AUCとpAUCによる評価

AUC

正常音と異常音の異常スコアをよりきれいに区別して付けられたかを、すべての評価音を使って評価する指標

AUCが高くなる場合

評価音	異常スコア
音声A	0.05
音声C	0.06
音声D	0.10
音声G	0.70
音声B	0.88
音声E	0.90

きれいに分かれている

AUCが低くなる場合

評価音	異常スコア
音声A	0.25
音声C	0.30
音声D	0.40
音声G	0.50
音声B	0.55
音声E	0.80

区別が見分けづらい

pAUC

正常音の誤検知を抑えながら異常音を検知できたか評価する指標

正常音100件、異常音20件を評価する例

pAUC	高くなる場合	低くなる場合
許容する正常音の誤検知	10件以内	10件以内
検知できた異常音	18件	6件
異常音の検知率	90%	30%

AUC・pAUCは1.0に近いほど性能が高い
0.5付近はランダムな判定に近い

pAUCは実際に運用した際に重要
pAUCが低いと誤警報が多くなる

3-7. 各モデル単独の評価とアンサンブル

モデル単体のAUC/pAUCの評価

方法	AUC	pAUC
メロスペクトログラム+CNN	0.5234	0.5263
BEATs	0.5807	0.5505
EAT	0.6597	0.5874
SSLAM	0.7195	0.6468

アンサンブル後のAUC/pAUCの評価

方法	AUC	pAUC
単独で最高のSSLAM	0.7195	0.6468
4モデルのアンサンブル 重み : Mel=0.3 BEATs=0.3 EAT=0.1 SSLAM=0.3	0.7754	0.6611
改善量	+0.0559	+0.0142

4. まとめと今後の展望

まとめ

- ・4つのモデルを組み合わせることで、単独モデルよりもAUC・pAUCが**向上した**
→ 各モデルが**異なる特徴を捉え**、**互いの誤判定を補うこと**で、アンサンブルの性能が向上した可能性がある
- ・どのモデルがどのような独自の特徴を捉え、性能向上に**貢献したのか分からない**

今後の展望


- ・各モデルがどのような**独自の特徴**を拾って、**性能向上に貢献したのか**を調査する
- ・周期性や周波数帯域の変化を**数値化**し、各モデルの**判定根拠**を詳しく分析する

- ・異常検知モデルの精度向上
→ AUC/pAUCを向上

今回値 : AUC : 0.7754 pAUC : 0.6611
将来値 : AUC : 0.85以上 pAUC : 0.8以上

3-8. DCASE Challengeのvalve音結果との比較

比較グラフ



---	AUC	pAUC	AUC差	pAUC差
今回の結果	0.7754	0.6611	---	---
中央値	0.7572	0.6512	-0.0182	-0.0099
最高値	0.9252	0.8694	+0.1498	+0.2083

Valve音単独では36チーム中**17位相当**
中位よりやや高い性能を示した
一方、DCASE内の最高値とは**差**があり、さらなる性能向上が必要である

9. アンサンブルの有効性調査

4モデルの組み合わせによってAUC、pAUCは向上した

どのモデルが性能向上に貢献したのか分からない

4モデルすべてが必要なのか分からない

各モデルがどの異常音を補っているのか分からない



1. 1モデルずつ除外するアブレーション実験
2. モデルごとに判定が異なる音声の比較

目次

1. 研究背景

2. 研究課題と目的

あああ

3. 研究全体の流れ

4. 4つの音響特徴抽出方法

5. 評価データ

6. 異常スコアとアンサンブル

7. 評価方法

あああ

8. 各モデル単独の評価とアンサンブル

9. アンサンブルの有効性調査

10. 結論と今後の展望

1. 研究背景

産業現場での異常音検知の重要性



工場の安全な稼働を維持する上で、機械の設備点検業務は非常に重要

産業現場において機械の音から自動で異常を発見する
異常音検知システムは盛んにおこなわれている

機械の異常を**早期に発見**することは、事故や故障の**拡大防止**につながる

人による点検には、**見逃し**や担当者による**判断の違い**がある



本研究では、機械の音から**自動で異常を発見する**異常音検知に取り組む

2. 研究課題と目的

課題①異常音データの収集が困難

→ 異常音データを使用せずに異常を検知できる教師なし異常検知の実現


課題②環境騒音による精度低下

→ 環境騒音の影響を受けにくい異常音検知システムの構築



正常音のみで学習し、工場騒音がある環境でも異常を
検知できるシステムの構築を目指す

3. 研究全体の流れ：異常音検知システムの構成



4. 4つの音響特徴抽出方法

方法	学習する特徴	機械音の中で捉えると期待される特徴
メロスペクトrogram+CNN	周波数や音量の細かな変化	特定周波数の増加、高音化・低音化
BEATs	音に共通する意味的なパターン	機械全体の動作音や、 正常時と大きく異なる音
EAT	音声全体と部分的な特徴	全体的な変化、周期の乱れ、 一瞬の衝撃音
SSLAM	数の音が重なった状態と それぞれの音源の特徴	機械音と背景騒音の重なりや、複数の機械 が同時に動作する環境の音



4つの方法は**学習方法**や**特徴**が異なるため、同じ対象機械から**異なる特徴を抽出する可能性**

5. 評価データ：評価に使用したValve音

DCASE Challenge Task2「機械状態監視のための初回無監視異常音検出」

対象機械から発せられる音が正常か異常かを識別するタスク異常音検知の手法について技術を競うワークショップ
6つの機械音が対象 → **その中の1つvalve音**で検証する

学習データには正常音のみを使用


評価データには正常音と異常音を使用



正常音



異常音



6. 異常スコアとアンサンブル：4つの評価結果のアンサンブル

アンサンブルとは

複数の特徴量やモデルの結果を**組み合わせて**、最終的な判定を行う手法

アンサンブルの仕組み

1. 同じテストvalve音データからメロスペクトrogram、BEATs、EAT、SSLAM
のそれぞれで、**異常スコアを算出**
2. その4つの異常スコアに**重みを設定**して統合し、**最大値**を最終の**異常スコア**にする
$$S_{\text{ensemble}} = W_{\text{Mel}} S_{\text{Mel}} + W_{\text{BEATs}} S_{\text{BEATs}} + W_{\text{EAT}} S_{\text{EAT}} + W_{\text{SSLAM}} S_{\text{SSLAM}}$$
 S : 異常スコア W : 重み
3. この処理を全テストデータに対して行って、**AUCとpAUCを算出する**



1つのモデルが**異常を見逃しても**、別のモデルの異常スコアによって
補うことを目的とする

7. 評価方法：AUCとpAUCによる評価

AUC

正常音と異常音を**全体として**
どの程度分離できたか

pAUC

正常音の**誤検知が少ない範囲で**、
異常音を検知できたか

①異常スコアを算出

評価データ音	正解	異常スコア
valve音E	異常	0.90
valve音F	正常	0.80
valve音B	異常	0.70
valve音C	正常	0.03
valve音D	異常	0.03
valve音A	正常	0.02

②閾値ごとに判定

例：閾値 0.04 以上を異常

E・F・Bを「異常」と判定

TPR（異常の検知率）


$$2 \div 3 = 0.67$$

FPR（正常の誤検知率）

$$1 \div 3 = 0.33$$

ROC上の点：(0.33, 0.67)

③ROC曲線



AUC・pAUCは**1.0に近いほど性能が高い**
0.5付近はランダムな判定に近い

8. 各モデル単独の評価とアンサンブル

モデル単体のAUC/pAUCの評価

方法	AUC	pAUC
メロスペクトログラム+CNN	0.5234	0.5263
BEATs	0.5807	0.5505
EAT	0.6597	0.5874
SSLAM	0.7195	0.6468

アンサンブル後のAUC/pAUCの評価

方法	AUC	pAUC
単独で最高のSSLAM	0.7195	0.6468
4モデルのアンサンブル 重み : Mel=0.3 BEATs=0.3 EAT=0.1 SSLAM=0.3	0.7754	0.6611
改善量	+0.0559	+0.0142

アブレーション実験



1モデルずつ異常スコアを組み合わせずに除外した結果

除外したモデル	AUC	4モデルからの低下
除外なし	0.7754	----
メロスペクトrogram + CNN	0.7725	- 0.0029
BEATs	0.7694	- 0.0060
EAT	0.7344	- 0.0410
SSLAM	0.6825	- 0.0929

各モデルだけが正解した異常音

正解したモデル	他のモデルが誤判定した正常音
メロスペクトrogram + CNN	6件
BEATs	7件
EAT	17件
SSLAM	15件

モデル除外時のAUC低下の棒グラフ



どのモデルにおいても除外した場合に性能が低下したため、
4モデル全てが性能向上に貢献した

モデルごとに判定が異なる音声の比較

各モデルだけが正解した異常音と同じ録音条件の正常音をメロスペクトログラムで比較
→ 耳だけでは分かりにくい周波数や周期の変化を画像として確認できる

メロスペクトログラムについて
音声を「縦軸：時間・横軸：周波数・色：音の強さ」で表したもの

比較対象の選び方：

異常音：対象モデルのみが正しく異常音と判定した音声データ


正常音：同じ録音条件を持つ正常音の音声データ

右画像には、上から順番に次の3つを表示

1. 同じ録音条件件を持つ正常音のメルスペクトログラム
2. 対象となる異常音のメルスペクトログラム
3. 正常音と異常音のメルスペクトログラムの絶対差分

差分 = |異常音のメルスペクトログラム - 正常音のメルスペクトログラム|


例：EATのメロスペクトログラム比較画像



モデルごとに判定が異なる音声の比較

正解したモデル	他のモデルが誤判定した正常音
EAT	17件
SSLAM	15件

EATの正常音/異常音比較




確認できた特徴

正常音よりも異常音の方が、周期的な縦線の回数が**少なかった**
約2,500～3,500 Hz付近に、音声全体を通して明確な差が見られた



EATは、Valve音全体の**周期的な変化**と、特定の**周波数帯に継続する変化**を組み合わせ検出した可能性

SSLAMの正常音/異常音比較



確認できた特徴

異常音では、縦線の一部が正常音より**弱く見える箇所**があった
約2,500～4,000 Hz付近に、音声全体を通した差が見られた
周期的な縦線だけでなく、その周囲にある継続的な帯状成分にも違いが見られた



SSLAMは、valve音の**周期的な動作音の強さ**だけでなく、その周囲に**重なる複数の周波数成分**を含めた変化を検出した可能性

研究全体の流れ：異常音検知システムの構成

各モデル学習の流れ



1. 一つのモデルで正常音の特徴を抽出する
2. その特徴をもとに正常音同士をグループ分け
3. グループにラベルを付ける
4. 新たな正常音の特徴からラベルを予測するようにモデルを学習
5. 正常音の多様なパターンを反映した正常分布を構築
6. これをメロスペクトログラム、BEATs、EAT、SSLAM同様に行う

各モデルの評価の流れ



1. 一つのモデルで評価音の特徴を抽出する
2. その特徴を特徴ベクトルに変換
3. 評価音と最も近い正常音のグループの距離を計算
4. その距離を評価音の異常スコアとする
5. これをメロスペクトログラム、BEATs、EAT、SSLAM同様に行う